

PROJET STATION TV



RAPPORT

SUIVI DES MODIFICATIONS DU DOCUMENT			
Version	Date	Validation	Commentaire
1.0	23/02/2026		Rédaction initiale

REDACTEUR : Dorian BRISSON	VALIDATEUR : Mathieu DELALANDRE
CLIENT : Polytech Tours	ENCADRANT : Mathieu DELALANDRE

REMERCIEMENTS

Je remercie M. Mathieu DELALANDRE pour l'encadrement scientifique et l'int gration au programme Station TV. Je remercie  galement la DSI de Polytech Tours pour le support mat riel et la supervision de la mise   niveau de la station Dell. Enfin, je remercie l' quipe LIFAT pour l'acc s aux jeux de donn es audio TNT et aux scripts existants utilis s comme base de travail.

Table des matières

1. Introduction	6
2. Contexte du projet et état de l'existant	8
2.1 Le projet Station TV au LIFAT	8
2.2 La transcription audio à grande échelle	8
2.3 Solution STT existante basée sur Whisper	9
2.4 Infrastructure matérielle existante.....	9
2.5 Problématiques identifiées et besoins du projet	10
3. Objectifs et contraintes du projet	10
3.1 Objectifs généraux	11
3.2 Objectifs fonctionnels	11
3.3 Objectifs de performance	12
3.4 Contraintes du projet	13
4. Organisation et méthodologie du projet	14
4.1 Organisation du projet.....	14
4.2 Choix méthodologique	14
4.3 Découpage en sprints	15
4.4 Suivi du projet et validation des livrables.....	16
4.5 Gestion des risques	16
4.6 Outils et environnement de travail.....	17
5. Architecture générale du système.....	17
5.1 Principes de conception	18
5.2 Vue d'ensemble de l'architecture	18
5.3 Architecture matérielle.....	19
5.4 Architecture logicielle	20
5.5 Flux de données et d'exécution	20
5.6 Justification de l'architecture retenue	21
6. Choix techniques et justification des solutions retenues	21
6.1 Choix du moteur de transcription automatique	21
6.2 Exécution sur architecture CPU.....	22
6.3 Parallélisation et traitement batch.....	23
6.4 Gestion de la mémoire	23
6.5 Mise en place des métriques de Qualité de Service	24
6.6 Synthèse des choix techniques	24
7. Réalisation et implémentation du système.....	25

7.1 Mise � niveau et validation de l’environnement mat�riel.....	25
7.2 Structuration du pipeline de transcription	25
7.3 Impl�mentation de la transcription multi-processus.....	26
7.4 Gestion des sorties et des journaux d’ex�cution	27
7.5 Supervision et collecte des m�triques QoS	27
7.6 Robustesse et gestion des erreurs	27
7.7 Bilan de l’impl�mentation.....	28
8. Campagnes de tests et protocole exp�rimental.....	28
8.1 Objectifs des campagnes de tests.....	28
8.2 Jeux de donn�es audio	28
8.3 Configuration mat�rielle et logicielle des tests	29
8.4 Protocole de caract�risation des performances ASR	29
8.5 D�tection des pics m�moire et I/O par NMS.....	30
8.6 Param�tres exp�rimentaux	32
8.7 M�thodologie de mesure des performances	33
8.8 Chargement et mise en cache des mod�les.....	33
8.9 Limites du protocole exp�rimental	33
8.10 Synth�se du protocole.....	34
9. R�sultats exp�rimentaux et analyse des performances	34
9.1 R�sultats globaux des campagnes de transcription	34
9.2 Analyse du d�bit de transcription (Throughput)	35
9.3 Temps moyen de traitement par fichier	36
9.4 Utilisation des ressources CPU	36
9.5 Consommation m�moire et stabilit� du syst�me.....	37
9.6 Taux de r�ussite des transcriptions.....	37
9.7 Utilisation des entr�es/sorties disque.....	37
9.8 Consommation �nerg�tique du syst�me.....	38
9.9 Analyse des pics m�moire	38
9.10 Analyse des pics I/O	38
9.11 Synth�se comparative des mod�les Whisper	40
9.12 Discussion et interpr�tation des r�sultats	41
10. Prise de recul, limites et perspectives	41
10.1 Stabilit� long terme et robustesse du syst�me.....	41
10.2 Apports du projet	42
10.3 Limites identifi�es	43

10.4 Perspectives d'�volution technique	44
10.4 Perspectives d'int�gration dans Station TV	44
10.5 Bilan personnel et conclusion g�n�rale.....	44

1. Introduction

La multiplication des contenus audiovisuels diffusés par les chaînes de télévision, les plateformes de replay et les services numériques pose aujourd’hui des défis majeurs en matière de traitement automatique de l’information. La télévision numérique terrestre (TNT) génère quotidiennement de grandes quantités de données audio et vidéo, dont l’exploitation manuelle est irréaliste à l’échelle industrielle. Dans ce contexte, les techniques d’analyse automatique des flux audiovisuels constituent un levier stratégique pour la recherche comme pour le développement de nouveaux services numériques.

Le projet Station TV, développé depuis 2019 au sein du Laboratoire d’Informatique Fondamentale et Appliquée de Tours (LIFAT), s’inscrit dans cette dynamique. Il vise à concevoir une plateforme de calcul parallèle dédiée à la capture, au traitement et à l’analyse automatique des chaînes de télévision issues de la TNT. Cette plateforme ne se limite pas à la simple acquisition des flux audiovisuels, mais propose un ensemble de services à forte valeur ajoutée, tels que la détection de publicité, l’analytics TV, le fact-checking, le scraping de données TV ou encore l’analyse sémantique multimodale.

Parmi ces services, la transcription audio automatique, également appelée Speech-To-Text (STT), occupe une place centrale. La transcription audio consiste à convertir un signal sonore en une représentation textuelle exploitable, généralement sous forme de texte brut (ASCII) ou de formats structurés (CSV, JSON). Cette étape constitue un point d’entrée essentiel pour les traitements linguistiques ultérieurs : recherche d’information, indexation sémantique, extraction d’entités nommées, résumé automatique ou détection de citations. La qualité et la performance du module de transcription conditionnent donc directement l’efficacité globale de l’ensemble de la chaîne de traitement Station TV.

Toutefois, la transcription audio appliquée aux flux télévisuels présente des difficultés spécifiques. Les données audio issues de la TNT sont dites complexes : présence de bruit de fond, musiques, jingles, voix multiples, chevauchements de locuteurs, variations d’accent et de débit de parole. À cela s’ajoute une contrainte majeure d’échelle, puisque la plateforme Station TV est amenée à traiter plusieurs centaines d’heures d’audio, voire davantage, sur des campagnes de transcription longues et continues. Une solution STT adaptée à ce contexte doit donc être à la fois robuste, précise et hautement performante, tout en restant compatible avec les ressources matérielles disponibles.

Une première solution de transcription à grande échelle a été mise en place au sein du projet Station TV sur la base de l’outil Whisper, un modèle de reconnaissance vocale développé par OpenAI. Cette solution a démontré des résultats qualitatifs satisfaisants, ainsi que des débits de transcription élevés pour des modèles de taille réduite ou intermédiaire. Néanmoins, l’utilisation de modèles Whisper de plus grande taille, visant une meilleure qualité de transcription, a rapidement mis en évidence des limitations matérielles et logicielles. Les besoins mémoire importants de ces modèles, combinés à une exécution parallèle intensive, entraînent des phénomènes de saturation de la mémoire vive, des instabilités du système et une dégradation des performances globales.

Le présent projet s'inscrit dans la continuité de ces travaux et vise à lever les limitations identifiées. Il repose sur une approche globale combinant évolution matérielle, optimisation logicielle et évaluation quantitative rigoureuse des performances. La station de calcul principale, une Dell Precision 5820, a été mise à niveau vers une configuration disposant de 256 Go de mémoire vive ECC, afin de supporter des charges de calcul élevées et l'exécution simultanée de modèles STT de grande taille. Sur cette base matérielle renforcée, des campagnes de transcription à l'échelle sont menées sur différents modèles Whisper (tiny, base, small, medium et large), en s'appuyant sur un protocole expérimental structuré.

Au-delà de la simple exécution des transcriptions, un axe majeur du projet concerne la mise en place de métriques de Qualité de Service (QoS). L'objectif est de caractériser de manière objective le comportement du système en mesurant, entre autres, le temps de traitement, le débit de transcription, l'utilisation des ressources CPU et mémoire, l'I/O du disque, la consommation et une estimation du prix. Ces métriques permettent non seulement de comparer différentes configurations et tailles de modèles, mais également de valider la stabilité du système lors de campagnes longues et intensives.

Enfin, le projet vise à préparer une campagne de transcription à très grande échelle selon une logique run / batch, compatible avec une intégration durable au sein de l'écosystème Station TV. Cette approche implique une industrialisation du pipeline de transcription, incluant la gestion des lots de fichiers audio, la supervision continue des ressources, la sauvegarde systématique des résultats et la reproductibilité des expérimentations. L'ensemble du travail s'inscrit ainsi dans une démarche d'ingénierie visant à fournir une solution exploitable, mesurable et évolutive.

Ce rapport présente l'ensemble des travaux réalisés dans le cadre de ce projet. Après avoir détaillé le contexte, les objectifs et l'organisation du projet, il décrit l'architecture matérielle et logicielle mise en œuvre, les choix techniques effectués et leur justification. Les résultats expérimentaux obtenus lors des campagnes de tests à l'échelle sont ensuite analysés à l'aide de métriques quantitatives, avant de conclure par une prise de recul critique et des perspectives d'évolution pour la plateforme Station TV.

2. Contexte du projet et état de l'existant

Le projet de transcription audio haute performance sur Station TV s'inscrit dans un cadre scientifique et technique déjà structuré, issu de plusieurs années de travaux menés au sein du Laboratoire d'Informatique Fondamentale et Appliquée de Tours (LIFAT). Avant d'aborder les développements réalisés dans ce projet, il est nécessaire de présenter le contexte global dans lequel il prend place, ainsi que l'état de l'existant sur lequel il s'appuie.

2.1 Le projet Station TV au LIFAT

Le projet Station TV a été initié en 2019 avec pour ambition de concevoir une plateforme de calcul parallèle dédiée au traitement automatique des flux télévisuels issus de la télévision numérique terrestre (TNT). Contrairement à une approche centrée uniquement sur la captation ou l'archivage de contenus audiovisuels, Station TV vise une exploitation intelligente et automatisée de ces flux, en combinant des techniques issues du traitement du signal, de l'intelligence artificielle et de l'analyse de données.

La plateforme Station TV regroupe aujourd'hui plusieurs services numériques complémentaires. Parmi ceux-ci figurent la capture intelligente de flux vidéo et audio, la détection automatique de séquences publicitaires, l'analyse statistique et sémantique des programmes télévisés, le fact-checking automatisé ainsi que le scraping de données liées aux contenus diffusés. L'ensemble de ces services repose sur une infrastructure matérielle mutualisée, pensée pour supporter des traitements intensifs et parallélisés sur de grandes quantités de données.

Dans cette architecture globale, la transcription audio automatique constitue une brique transversale essentielle. Elle permet de transformer le contenu sonore des programmes télévisés en données textuelles, lesquelles deviennent ensuite exploitables par des modules aval d'analyse linguistique et sémantique. Sans une transcription fiable et performante, l'ensemble des traitements basés sur le texte perd en pertinence ou devient inapplicable à grande échelle.

2.2 La transcription audio à grande échelle

La transcription audio, ou Speech-To-Text (STT), consiste à convertir un signal audio continu en une séquence de mots ou de phrases. Bien que ce problème soit étudié depuis plusieurs décennies, son application à des flux télévisuels réels et à grande échelle pose des défis spécifiques. Les signaux audios issus de la TNT sont caractérisés par une forte hétérogénéité : diversité des locuteurs, superposition de voix, bruit ambiant, musique de fond, variations de qualité sonore et de débit de parole. Ces facteurs dégradent significativement les performances des systèmes de reconnaissance vocale classiques.

À ces difficultés qualitatives s'ajoute une contrainte quantitative majeure. La plateforme Station TV est amenée à traiter des centaines, voire des milliers d'heures d'audio dans le cadre de campagnes de transcription longues. Une solution STT adaptée doit donc non seulement fournir une transcription de qualité acceptable, mais également être capable de soutenir un débit de traitement élevé, tout en maintenant une utilisation maîtrisée des ressources matérielles, notamment le processeur et la mémoire vive.

Ces contraintes excluent de fait les solutions STT naïves ou interactives, conçues pour un usage ponctuel ou en temps réel sur des volumes limités. Elles imposent au contraire une approche orientée traitement batch, parallélisation et optimisation des ressources, avec une attention particulière portée à la stabilité du système sur des durées d'exécution prolongées.

2.3 Solution STT existante basée sur Whisper

Dans le cadre des travaux précédents du projet Station TV, une première solution de transcription à grande échelle a été développée en s'appuyant sur Whisper, un modèle de reconnaissance vocale open source proposé par OpenAI. Whisper se distingue par sa capacité à traiter des données audios multilingues et bruitées, tout en offrant différents niveaux de qualité de transcription selon la taille du modèle utilisé (tiny, base, small, medium, large).

Cette solution a permis de démontrer la faisabilité de la transcription automatique de flux TNT à l'échelle, avec des débits significatifs pour les modèles de taille réduite et intermédiaire. Les campagnes de test ont montré que Whisper présente une robustesse appréciable face aux conditions audio complexes, ce qui en fait un candidat pertinent pour une intégration au sein de Station TV.

Cependant, l'utilisation de Whisper dans un contexte de calcul intensif sur CPU a rapidement mis en évidence plusieurs limitations. Les modèles de grande taille, en particulier medium et large, présentent des besoins mémoire élevés. Lors d'exécutions parallèles visant à augmenter le débit global, ces besoins entraînent une saturation rapide de la mémoire vive disponible, provoquant des ralentissements, des phénomènes de trashing mémoire, voire des instabilités système. Par ailleurs, l'absence d'un cadre formel de supervision rendait difficile l'analyse fine des performances et l'identification des goulots d'étranglement.

2.4 Infrastructure matérielle existante

La plateforme de calcul principale utilisée pour la transcription audio repose sur une station Dell Precision 5820, équipée d'un processeur Intel Xeon W-2295 disposant de 18 cœurs physiques et 36 threads. Cette machine a été conçue pour des charges de travail intensives et parallélisées, mais sa configuration mémoire initiale s'est révélée insuffisante pour supporter durablement des campagnes de transcription utilisant les modèles Whisper de grande taille.

Avant le démarrage du présent projet, la station disposait d'une capacité mémoire limitée, ce qui imposait des compromis importants entre qualité de transcription et stabilité du système.

Les exécutions de longue durée étaient particulièrement sensibles aux fuites mémoire et aux pics de consommation, rendant difficile toute industrialisation du pipeline de transcription.

Ces limitations matérielles ont constitué un frein majeur à l'exploitation à grande échelle de Whisper au sein de Station TV, et ont motivé la décision de faire évoluer la configuration matérielle de la station de calcul.

Élément	Valeur
Machine	Dell Precision 5820
CPU	Intel Xeon W-2295
Cœurs / Threads	18 / 36
RAM avant	64 Go
RAM après	256 Go ECC
OS	Windows

2.5 Problématiques identifiées et besoins du projet

L'analyse de l'existant a permis d'identifier plusieurs problématiques clés, qui constituent le point de départ du présent projet :

- Une capacité mémoire insuffisante pour l'exécution stable de modèles STT de grande taille en parallèle ;
- Une difficulté à caractériser précisément les performances du pipeline de transcription en l'absence de métriques QoS centralisées ;
- Une instabilité du système lors de campagnes longues et intensives, incompatible avec une exploitation industrielle ;
- Une absence de structuration formelle des campagnes run / batch, limitant la reproductibilité et la maintenabilité des expérimentations.

Face à ces constats, le projet de transcription audio haute performance sur Station TV vise à apporter une réponse globale, combinant une montée en puissance matérielle, une structuration logicielle du pipeline de transcription et la mise en place d'outils de mesure et d'analyse des performances. Ces éléments constituent le socle sur lequel reposent les développements et expérimentations présentés dans les chapitres suivants.

3. Objectifs et contraintes du projet

Le projet de transcription audio haute performance sur Station TV s'inscrit dans une démarche d'ingénierie visant à transformer une solution fonctionnelle mais limitée en un système robuste, mesurable et exploitable à grande échelle. Afin d'évaluer objectivement les travaux réalisés, il est nécessaire de définir clairement les objectifs poursuivis ainsi que les contraintes

dans lesquelles le projet s'inscrit. Ces éléments constituent le cadre de référence utilisé tout au long du développement et de l'analyse des résultats.

3.1 Objectifs généraux

L'objectif principal du projet est de renforcer et d'industrialiser la chaîne de transcription audio automatique de la plateforme Station TV, afin de permettre le traitement massif de données audio issues de la TNT avec un niveau de qualité et de performance compatible avec une exploitation durable.

Cet objectif global se décline selon trois axes complémentaires :

1. **Montée en charge matérielle**

Permettre l'exécution stable de modèles de reconnaissance vocale de grande taille en augmentant significativement la capacité mémoire de la station de calcul principale, tout en garantissant la compatibilité matérielle et la fiabilité du système.

2. **Performance et scalabilité logicielle**

Optimiser le pipeline de transcription afin d'augmenter le débit global de traitement, notamment par l'utilisation de traitements parallèles et batch, tout en maîtrisant l'utilisation des ressources CPU et mémoire.

3. **Mesurabilité et validation quantitative**

Mettre en place un ensemble de métriques de Qualité de Service (QoS) permettant de caractériser objectivement les performances et la stabilité du système de transcription.

Ces axes visent à dépasser une simple preuve de concept pour aboutir à une solution techniquement maîtrisée et intégrable au sein de l'écosystème Station TV.

3.2 Objectifs fonctionnels

Sur le plan fonctionnel, le système développé doit répondre aux exigences suivantes :

- Assurer la transcription automatique de fichiers audio issus de la TNT, potentiellement longs et complexes.
- Produire des sorties textuelles exploitables sous différents formats (texte brut, formats structurés).
- Permettre l'exécution de campagnes de transcription batch, organisées en lots, sans intervention manuelle continue.
- Garantir la traçabilité des traitements, via des journaux d'exécution et des sauvegardes des résultats.
- Fournir des données exploitables par les modules avals de la plateforme Station TV.

Ces objectifs fonctionnels conditionnent la conception du pipeline logiciel et la structuration des campagnes run / batch.

3.3 Objectifs de performance

Au-del  des aspects fonctionnels, le projet vise   atteindre des objectifs de performance clairement d finis. Afin de les formaliser, plusieurs m triques quantitatives sont introduites.

3.3.1 Temps de traitement

Soit un ensemble de fichiers audio   transcrire, repr sentant une dur e audio totale not e :

$$T_{\text{audio}} = \sum_{i=1}^N d_i$$

o  d_i correspond   la dur e du fichier audio i , et N au nombre total de fichiers trait s.

Le temps r el total n cessaire pour effectuer la transcription est not  :

$$T_{\text{r el}}$$

Il correspond au temps  coul  entre le lancement et la fin compl te de la campagne de transcription.

3.3.2 D bit de transcription (Throughput)

Le d bit de transcription,  galement appel  *throughput*, constitue une m trique centrale du projet. Il est d fini comme le rapport entre la dur e audio totale trait e et le temps r el n cessaire au traitement :

$$Th = \frac{T_{\text{audio}}}{T_{\text{r el}}}$$

Cette grandeur est adimensionnelle et s'exprime en « fois le temps r el ». Par exemple, un d bit $Th = 5$ signifie que le syst me traite cinq heures d'audio en une heure r elle.

L'objectif du projet est d'atteindre des valeurs de throughput suffisantes pour rendre la transcription   grande  chelle viable, tout en tenant compte de la taille du mod le Whisper utilis .

3.3.3 Temps moyen par fichier

Une m trique compl mentaire consiste   mesurer le temps moyen de traitement par fichier audio :

$$T_{\text{moy}} = \frac{T_{\text{r el}}}{N}$$

Cette mesure permet d’analyser la régularité du pipeline et d’identifier d’éventuelles variations de performance liées à la durée ou à la complexité des fichiers audio.

3.3.4 Taux de réussite

La robustesse du système est évaluée à travers le taux de réussite des transcriptions, défini comme :

$$R = \frac{N_{\text{succès}}}{N_{\text{total}}}$$

où $N_{\text{succès}}$ représente le nombre de fichiers correctement transcrits, et N_{total} le nombre total de fichiers soumis au pipeline.

Un taux de réussite proche de 1 est requis pour considérer le système comme exploitable à l’échelle industrielle.

3.4 Contraintes du projet

Les objectifs précédemment définis doivent être atteints en respectant un ensemble de contraintes techniques, matérielles et organisationnelles.

3.4.1 Contraintes matérielles

Le projet repose exclusivement sur une architecture CPU, sans recours à l’accélération GPU. Ce choix est imposé par l’infrastructure existante et par des considérations de stabilité et de reproductibilité. La montée en charge repose donc principalement sur :

- La parallélisation multi-processus,
- L’exploitation des cœurs et threads CPU,
- Une gestion rigoureuse de la mémoire vive.

3.4.2 Contraintes logicielles

Le pipeline de transcription doit être compatible avec les environnements utilisés au sein de la plateforme Station TV. Il doit également être suffisamment robuste pour supporter des exécutions longues, potentiellement de plusieurs heures ou jours, sans intervention manuelle.

La gestion des erreurs, des journaux d’exécution et des sauvegardes constitue ainsi une contrainte forte de conception.

3.4.3 Contraintes d’exploitation

Enfin, le système développé doit être exploitable par d'autres acteurs du projet Station TV. Cela implique :

- Une configuration reproductible,
- Des paramètres clairement définis,
- Une structuration claire des campagnes de transcription.

Ces contraintes orientent le projet vers une solution industrialisable plutôt qu'un prototype expérimental.

4. Organisation et méthodologie du projet

La réussite d'un projet de transcription audio à grande échelle ne repose pas uniquement sur des choix techniques pertinents, mais également sur une organisation rigoureuse du travail et une méthodologie adaptée aux contraintes du contexte. Le projet Station TV — Transcription audio haute performance s'inscrit dans un cadre à la fois académique, expérimental et industriel, impliquant des exigences de traçabilité, de validation et de robustesse. Ce chapitre décrit l'organisation adoptée, la méthodologie de développement retenue ainsi que les mécanismes de suivi et de gestion des risques mis en place.

4.1 Organisation du projet

Le projet est mené dans le cadre du module Projet de Recherche et d'Innovation (PRI) de cinquième année à Polytech Tours. J'ai réalisé ce projet sous la direction scientifique d'un enseignant-chercheur de Polytech Tours : M. DELALANDRE, avec le support technique de la DSI de Polytech Tours pour les aspects matériels.

Cette configuration implique une organisation claire des rôles et responsabilités. J'assume à la fois les fonctions de chef de projet et d'ingénieur d'études, ce qui comprend la planification des tâches, la réalisation technique, la rédaction de la documentation et l'analyse des résultats. L'encadrant scientifique intervient dans la définition des orientations techniques, la validation des choix méthodologiques et l'évaluation progressive des livrables. La DSI assure quant à elle la supervision des opérations matérielles critiques, notamment lors de la mise à niveau de la station de calcul.

Cette organisation favorise une grande autonomie dans la conduite du projet, tout en garantissant un cadre de validation régulier et une cohérence avec les objectifs scientifiques du programme Station TV.

4.2 Choix méthodologique

Compte tenu de la nature du projet — expérimental, fortement technique et mené par un seul développeur — une méthodologie agile a été retenue. Cette approche permet de concilier flexibilité, itérations rapides et validation progressive des résultats.

Le projet est structuré en sprints successifs. Chaque sprint est associé à des objectifs clairement identifiés, des tâches techniques précises et des livrables vérifiables. Cette organisation permet :

- D'isoler les différentes phases du projet (préparation, développement, tests, validation),
- De limiter les risques liés à des changements tardifs,
- D'assurer une progression régulière et mesurable.

La méthodologie adoptée privilégie une approche incrémentale, dans laquelle chaque itération apporte une amélioration fonctionnelle ou une meilleure compréhension du comportement du système.

4.3 Découpage en sprints

Le projet a été découpé en plusieurs sprints, correspondant aux grandes étapes de son déroulement.

Le **Sprint 1** est consacré à la préparation de l'environnement technique. Il inclut la mise à niveau matérielle de la station Dell Precision 5820, l'installation et la validation des 256 Go de mémoire ECC, et la vérification du système.

Le **Sprint 2** porte sur la rédaction et la validation des documents de cadrage du projet, tels que le cahier des charges, la fiche d'ouverture de projet, les SPER, les spécifications fonctionnelles et techniques et le plan de développement. Cette phase permet de formaliser les objectifs, les contraintes et la méthodologie, et constitue un socle de référence partagé entre moi, l'encadrant et les parties prenantes.

Le **Sprint 3** est dédié à la réappropriation de la solution de transcription existante et à l'optimisation du pipeline logiciel. Ils incluent l'analyse du fonctionnement interne de Whisper, la rédaction d'un dossier de conception détaillé et général ainsi que la mise en place des mécanismes de parallélisation et de gestion mémoire.

Le **Sprint 4** est centré sur la définition et l'implémentation des métriques de Qualité de Service. Il vise à instrumenter le pipeline de transcription afin de collecter automatiquement les données nécessaires à l'évaluation des performances, telles que l'utilisation CPU et mémoire, la consommation, le prix, le débit de transcription et la stabilité du système.

Enfin, le **Sprint 5** correspond à la phase de tests intensifs et de validation finale. Il comprend les campagnes de transcription à grande échelle sur les modèles de plus haute qualité, l'analyse détaillée des résultats obtenus et la rédaction du rapport final.

Ce découpage en sprints permet de structurer le projet autour d'objectifs intermédiaires clairs, tout en assurant une continuité logique entre les différentes phases.

4.4 Suivi du projet et validation des livrables

Le suivi du projet repose sur des échanges réguliers avec l'encadrant scientifique. Des réunions de suivi sont organisées à la fin de chaque sprint afin de présenter l'avancement, de discuter des résultats obtenus et de valider les livrables associés. Des points intermédiaires plus informels peuvent également avoir lieu, notamment lors de difficultés techniques ou de décisions importantes.

Chaque livrable est évalué selon plusieurs critères :

- Conformité aux objectifs définis dans le cahier des charges,
- Stabilité et robustesse des solutions proposées,
- Clarté de la documentation associée,
- Pertinence de l'analyse des résultats.

La validation progressive des livrables permet de limiter les écarts par rapport aux objectifs initiaux et d'assurer la cohérence globale du projet.

4.5 Gestion des risques

La nature expérimentale et intensive du projet implique plusieurs risques susceptibles d'impacter son déroulement. Une analyse des risques a donc été menée en amont afin d'identifier les événements critiques et de définir des plans d'atténuation adaptés.

N°	Risque	Probabilité	Impact	Criticité	Niveau
1	Surcharge mémoire / crash système	4	4	16	Élevé
2	Dépendance à une seule personne	3	3	9	Moyen
3	Instabilité du modèle Whisper	3	4	12	Moyen
4	Perte ou corruption de données	2	4	8	Modéré
5	Panne matérielle (RAM / Dell 5820)	2	5	10	Moyen
6	Erreur d'interprétation QoS	2	3	6	Modéré
7	Retard de validation documentaire	2	2	4	Faible

Les principaux risques identifiés concernent la saturation de la mémoire, l'instabilité du pipeline lors d'exécutions longues, la perte de données et la dépendance à une seule personne pour le développement et la maintenance du système. Pour chacun de ces risques, des mesures préventives ont été mises en place, telles que la surveillance continue de l'utilisation des ressources, la limitation de la taille des lots de fichiers, la sauvegarde régulière des résultats et la documentation systématique des évolutions du code.

Cette gestion proactive des risques contribue à sécuriser le projet et à garantir la fiabilité des résultats obtenus.

4.6 Outils et environnement de travail

Le projet s'appuie sur un ensemble d'outils cohérents couvrant l'ensemble du cycle de développement. Le code source et la documentation sont versionnés à l'aide d'un système de gestion de versions, permettant de suivre précisément l'évolution du pipeline de transcription. Les scripts de traitement, de supervision et d'analyse sont développés en Python, dans un environnement reproductible.

La documentation technique et les rapports intermédiaires sont centralisés et versionnés, afin d'assurer la traçabilité des décisions et des résultats. Cette organisation facilite la collaboration avec l'encadrant et garantit la pérennité du travail réalisé au-delà du cadre du projet.

GitHub : https://github.com/dorianDB/PRI_5A_Station_TV

5. Architecture générale du système

Le projet de transcription audio haute performance sur Station TV repose sur une architecture logicielle et mat rielle con ue pour r pondre   des contraintes fortes de volum trie, de performance et de robustesse. L’objectif de cette architecture est de permettre l’ex cution de campagnes de transcription   grande  chelle, tout en assurant une utilisation ma tris e des ressources de calcul et une observabilit  fine du comportement du syst me.

Ce chapitre pr sente l’architecture globale retenue, les principaux modules qui la composent, ainsi que les flux de donn es et d’ex cution qui structurent le pipeline de transcription.

5.1 Principes de conception

La conception de l’architecture s’appuie sur plusieurs principes directeurs, issus   la fois des contraintes du projet et des bonnes pratiques en ing nierie logicielle pour les syst mes intensifs.

Le premier principe est la modularit . Le pipeline de transcription est d coup  en modules fonctionnels clairement identifi s, chacun ayant une responsabilit  pr cise. Cette approche facilite la compr hension du syst me, l’ volution ind pendante des composants et la maintenance   long terme.

Le second principe est la scalabilit  horizontale sur architecture CPU. En l’absence d’acc l ration GPU, l’augmentation des performances repose principalement sur la parall lisation multi-processus et sur une exploitation efficace des c urs et threads du processeur. L’architecture doit donc permettre de lancer plusieurs traitements de transcription en parall le, tout en  vitant les conflits de ressources.

Le troisi me principe est l’observabilit . Contrairement   un pipeline opaque, le syst me doit  tre instrument  afin de fournir des indicateurs mesurables sur son comportement : temps de traitement, d bit, utilisation CPU et m moire, consommation, I/O du disque et stabilit  des ex cutions. Ces informations sont indispensables pour analyser les performances et valider les objectifs d finis au chapitre pr c dent.

Enfin, l’architecture vise une industrialisation progressive. Le pipeline n’est pas con u comme un simple script exp rimental, mais comme un syst me structur , capable d’ tre int gr  durablement   l’ cosyst me Station TV et utilis  par d’autres acteurs du projet.


5.2 Vue d’ensemble de l’architecture

L’architecture globale du syst me de transcription repose sur une station de calcul centrale, la Dell Precision 5820, sur laquelle s’ex cutent l’ensemble des traitements. Cette station agit comme un n ud de calcul autonome, capable de traiter des volumes importants de donn es audio en mode batch.

Sur le plan logiciel, le syst me est organis  autour de quatre grands modules fonctionnels :

1. Un module de prétraitement audio, chargé de préparer les fichiers audios en entrée.
2. Un module de transcription automatique, basé sur Whisper, qui constitue le cœur du pipeline.
3. Un module de supervision et de qualité de service (QoS), dédié à la collecte et à l'analyse des métriques de performance.
4. Un module d'export et d'intégration, assurant la production de résultats exploitables par la plateforme Station TV.

Ces modules sont orchestrés par des scripts de pilotage qui définissent le déroulement des campagnes de transcription, depuis la préparation des données jusqu'à la génération des rapports finaux.



5.3 Architecture matérielle

La plateforme matérielle utilisée pour le projet est une station Dell Precision 5820, équipée d'un processeur Intel Xeon W-2295 disposant de 18 cœurs physiques et de 36 threads logiques. Cette configuration permet l'exécution simultanée de plusieurs processus de transcription, chacun exploitant un sous-ensemble des ressources CPU disponibles.

La mémoire vive constitue un élément central de l'architecture. La mise à niveau vers 256 Go de RAM ECC permet de supporter les besoins mémoire importants des modèles de reconnaissance vocale de grande taille, tout en réduisant les risques d'erreurs liées à la corruption de données. Cette capacité mémoire élevée est essentielle pour éviter le recours au swapping disque, fortement pénalisant pour les performances.

Le stockage est réparti entre un espace local, utilisé pour les traitements temporaires et les écritures intensives, et des espaces de stockage distants (NAS) destinés à l'archivage des données audio et des résultats de transcription. Cette séparation permet de limiter les goulots d'étranglement liés aux entrées/sorties disque lors des campagnes intensives.

L'ensemble de l'architecture matérielle est exploité dans un environnement système compatible avec les outils logiciels utilisés, garantissant la stabilité des exécutions et la reproductibilité des expériences.

5.4 Architecture logicielle

Sur le plan logiciel, le syst me de transcription est impl ment  sous la forme d’un ensemble de modules Python interconnect s. Chaque module correspond   une fonction sp cifique du pipeline et communique avec les autres via des structures de donn es et des fichiers interm diaires clairement d finis.

Le module de pr traitement audio est responsable de la gestion des fichiers audio en entr e. Il assure la conversion des formats si n cessaire, la normalisation des param tres audio (fr quence d’ chantillonnage, nombre de canaux). Cette  tape permet de garantir une homog n it  des donn es d’entr e et de limiter les erreurs lors de la transcription.

Le module de transcription automatique constitue le c ur du syst me. Il encapsule l’utilisation du moteur Whisper et orchestre l’ex cution des transcriptions en mode batch et multi-processus. Ce module g re le chargement des mod les, la distribution des fichiers audio entre les processus, ainsi que la production des sorties textuelles. Il est con u pour maximiser le d bit global tout en respectant les contraintes m moire et CPU.

Le module de supervision et de QoS fonctionne en parall le du module de transcription. Il collecte en continu des informations sur l’utilisation des ressources syst me et sur le d roulement des traitements. Les donn es recueillies sont stock es sous forme structur e puis sous forme graphique afin de permettre une analyse a posteriori et la g n ration de rapports de performance.

Enfin, le module d’export et d’int gration assure la mise en forme finale des r sultats. Il transforme les transcriptions brutes en formats exploitables par les autres composants de la plateforme Station TV et garantit la coh rence des m tadonn es associ es.

5.5 Flux de donn es et d’ex cution

Le fonctionnement global du syst me peut  tre d crit comme une cha ne de traitement s quentielle et parall le.

Dans un premier temps, les fichiers audio issus de la TNT sont identifi s et pr par s par le module de pr traitement. Ces fichiers constituent les donn es d’entr e du pipeline.

Dans un second temps, les fichiers pr par s sont r partis entre plusieurs processus de transcription, lanc s en parall le sur la station de calcul. Chaque processus applique le mod le Whisper s lectionn  aux fichiers qui lui sont attribu s. Cette phase repr sente la charge de calcul principale du syst me.

Parall lement   l’ex cution des transcriptions, le module de supervision collecte les m triques de performance, sans interf rer avec le d roulement des traitements. Cette s paration logique permet de mesurer le comportement du syst me sans perturber les r sultats.

Enfin, les transcriptions produites et les métriques collectées sont consolidées et exportées sous forme de fichiers structurés, de graphiques et de rapports, qui constituent les sorties finales du pipeline.

5.6 Justification de l'architecture retenue

L'architecture décrite ci-dessus répond aux objectifs et contraintes définis précédemment. La modularité facilite l'évolution future du système, notamment l'intégration de nouveaux moteurs de transcription ou de nouvelles métriques de QoS. La parallélisation permet d'atteindre des débits de transcription compatibles avec un usage à grande échelle. L'instrumentation du pipeline garantit une analyse fine des performances et une validation quantitative des résultats.

Cette architecture constitue ainsi un compromis équilibré entre performance, robustesse et maintenabilité, adapté au contexte du projet Station TV et aux besoins.

6. Choix techniques et justification des solutions retenues

Le développement d'un système de transcription audio à grande échelle impose de nombreux choix techniques, tant sur le plan matériel que logiciel. Ces choix conditionnent directement les performances, la stabilité et la capacité d'industrialisation du pipeline. Ce chapitre présente les principales décisions techniques prises dans le cadre du projet Station TV — Transcription audio haute performance, ainsi que les justifications associées au regard des objectifs et contraintes définis précédemment.

6.1 Choix du moteur de transcription automatique

6.1.1 Sélection de Whisper comme solution STT

Le moteur de transcription retenu pour le projet est Whisper, un modèle de reconnaissance vocale développé par OpenAI. Ce choix s'inscrit dans la continuité des travaux antérieurs menés au sein du projet Station TV, ce qui présente plusieurs avantages. D'une part, Whisper a déjà été évalué sur des données audio issues de la TNT et a démontré une robustesse satisfaisante face à des signaux complexes. D'autre part, son intégration existante au sein de la plateforme permet de capitaliser sur les développements précédents et d'assurer une compatibilité avec les outils et formats déjà utilisés.

Whisper se distingue également par la disponibilité de plusieurs tailles de modèles, offrant un compromis progressif entre qualité de transcription et coût de calcul. Cette caractéristique est particulièrement pertinente dans un contexte de transcription à l'échelle, où le choix du modèle peut être adapté en fonction des objectifs de qualité et de performance.

6.1.2 Comparaison avec d'autres solutions STT

D'autres solutions de reconnaissance vocale existent, qu'elles soient open source ou propri taires. Cependant, nombre d'entre elles pr sentent des limitations incompatibles avec le contexte du projet Station TV. Certaines solutions propri taires imposent des co ts d'utilisation  lev s ou des contraintes li es   l'h bergement des donn es, incompatibles avec un traitement local de donn es sensibles. D'autres solutions open source offrent des performances limit es sur des donn es bruit es ou multilingues, ou ne disposent pas de mod les suffisamment robustes pour un usage   grande  chelle.

Au regard de ces  l ments, Whisper appara t comme un compromis pertinent entre qualit , robustesse et flexibilit , tout en restant int grable dans une architecture locale et contr l e.

6.2 Ex cution sur architecture CPU

6.2.1 Justification du choix CPU-only

Le projet repose volontairement sur une ex cution CPU-only, sans recours   l'acc l ration GPU. Ce choix est principalement dict  par les contraintes mat rielles et organisationnelles de la plateforme Station TV. La station de calcul principale ne dispose pas de ressources GPU d di es suffisamment dimensionn es pour supporter des campagnes de transcription intensives, et l'ajout de telles ressources aurait impliqu  des co ts et des contraintes suppl mentaires.

Par ailleurs, l'ex cution CPU-only pr sente des avantages en termes de reproductibilit  et de stabilit . Les comportements des traitements CPU sont g n ralement plus pr visibles sur des ex cutions longues, ce qui est un crit re important pour des campagnes run / batch pouvant durer plusieurs heures ou jours.

6.2.2 Implications sur la conception du pipeline

Le choix d'une architecture CPU-only implique une attention particuli re port e   la gestion des ressources. Les performances globales du syst me reposent principalement sur :

- L'exploitation efficace du parall lisme multi-processus.
- La r partition  quilibr e des charges de calcul.
- La ma trise de la consommation m moire des mod les STT.

Ces contraintes ont directement influenc  les choix de parall lisation et de structuration du pipeline de transcription.

6.3 Parallélisation et traitement batch

6.3.1 Approche multi-processus

Afin d'augmenter le débit global de transcription, le pipeline repose sur une exécution multi-processus. Plusieurs instances du moteur de transcription sont lancées en parallèle, chacune traitant un sous-ensemble des fichiers audio. Cette approche permet d'exploiter les cœurs et threads disponibles sur le processeur Xeon W-2295, tout en évitant les limitations du multi-threading Python liées au Global Interpreter Lock (GIL).

Le nombre de processus lancés est un paramètre clé du système. Un nombre trop faible de processus conduit à une sous-utilisation des ressources CPU, tandis qu'un nombre trop élevé augmente les risques de saturation mémoire et de contention des ressources. Le projet vise ainsi à identifier un compromis optimal entre parallélisme et stabilité.

Bien que le processeur Intel Xeon W-2295 dispose de 36 threads logiques, l'exploitation simultanée de l'ensemble de ces threads ne conduit pas nécessairement aux meilleures performances globales.

Les expérimentations ont montré qu'une configuration limitant le nombre de processus actifs à $k = 30$ permet d'éviter les phénomènes de contention excessive et de thrashing mémoire, en particulier lors de l'utilisation des modèles Whisper de grande taille.

Ce choix constitue un compromis entre maximisation du parallélisme CPU et maintien de la stabilité du système lors d'exécutions longues et intensives, tout en assurant un throughput global élevé.

6.3.2 Organisation run / batch

Le traitement des données audio est organisé selon une logique run / batch. Une campagne de transcription correspond à un run, au cours duquel un ensemble de fichiers audio est traité selon une configuration donnée (modèle Whisper, nombre de processus, paramètres audio). Les fichiers sont regroupés en batches, permettant de structurer le traitement et de limiter l'impact d'éventuelles erreurs.

Cette organisation facilite la reprise des traitements en cas d'incident, la comparaison de différentes configurations et la reproductibilité des expériences. Elle constitue un prérequis essentiel à l'industrialisation du pipeline.

6.4 Gestion de la mémoire

6.4.1 Problématique mémoire des modèles Whisper

Les modèles de reconnaissance vocale de grande taille, tels que medium et large, présentent des besoins mémoire importants. Lorsqu'ils sont chargés simultanément dans plusieurs

processus, la consommation mémoire globale peut rapidement atteindre des valeurs critiques, entraînant un recours au swapping disque ou des instabilités système.

La gestion de la mémoire constitue donc un enjeu central du projet. La mise à niveau matérielle vers 256 Go de RAM ECC répond à cette problématique, mais elle ne suffit pas à elle seule à garantir la stabilité du système.

6.4.2 Stratégies de limitation et de contrôle

Afin de maîtriser la consommation mémoire, plusieurs stratégies sont mises en œuvre :

- Limitation du nombre de processus simultanés en fonction du modèle utilisé ;
- Structuration des campagnes de transcription en lots de taille contrôlée ;
- Surveillance continue de l'utilisation mémoire via les métriques QoS.

Ces mécanismes permettent d'anticiper les situations de saturation et d'ajuster les paramètres d'exécution en conséquence.

6.5 Mise en place des métriques de Qualité de Service

6.5.1 Rôle des métriques QoS

La mise en place de métriques de Qualité de Service répond à un double objectif. D'une part, elle permet de mesurer objectivement les performances du système de transcription. D'autre part, elle fournit des outils d'aide à la décision pour l'optimisation et la validation des configurations testées.

Les métriques retenues couvrent plusieurs dimensions : performance temporelle, utilisation des ressources, stabilité.

6.5.2 Justification des métriques retenues

Le throughput est utilisé comme indicateur principal de performance, car il permet de comparer des campagnes de transcription indépendamment de leur durée totale. L'utilisation CPU et mémoire permet d'identifier les goulots d'étranglement matériels.

L'association de ces métriques permet d'analyser les compromis entre rapidité et consommation de ressources, et constitue une base solide pour la comparaison des modèles Whisper et des configurations testées.

6.6 Synthèse des choix techniques

Les choix techniques effectués dans le cadre de ce projet résultent d'un compromis entre contraintes matérielles, exigences de performance et objectifs d'industrialisation. Le recours à Whisper comme moteur STT, l'exécution CPU-only, la parallélisation multi-processus, la structuration run / batch et la mise en place de métriques QoS forment un ensemble cohérent, adapté aux besoins spécifiques de la plateforme Station TV.

Ces choix constituent le socle sur lequel reposent les implémentations détaillées dans le chapitre suivant, ainsi que les campagnes de tests et d'évaluation présentées par la suite.

7. Réalisation et implémentation du système

Ce chapitre décrit la mise en œuvre concrète du système de transcription audio haute performance développé dans le cadre du projet Station TV. Il présente la traduction opérationnelle des choix techniques exposés au chapitre précédent, en détaillant l'organisation du pipeline, l'implémentation des principaux modules et les mécanismes mis en place pour garantir la robustesse et la performance du système lors d'exécutions à grande échelle.

L'objectif n'est pas de fournir une description exhaustive du code source, mais de mettre en évidence les principes d'implémentation, les décisions structurantes et les difficultés rencontrées, afin de montrer comment le système a été conçu pour répondre aux contraintes identifiées.

7.1 Mise à niveau et validation de l'environnement matériel

La première étape de la réalisation a été la mise à niveau de la station Dell Precision 5820 vers une configuration disposant de 256 Go de mémoire vive ECC. Cette opération a été réalisée sous la supervision de la DSI, afin de garantir la compatibilité.

Après l'installation physique des barrettes mémoire, plusieurs vérifications ont été effectuées : reconnaissance complète de la mémoire par le système, fonctionnement en mode quad-channel. Ces vérifications sont essentielles, car toute instabilité matérielle aurait compromis la fiabilité des campagnes de transcription à venir.

La validation de l'environnement matériel a constitué un prérequis indispensable avant toute expérimentation logicielle, en particulier pour les modèles Whisper de grande taille, fortement consommateurs de mémoire.

7.2 Structuration du pipeline de transcription

Le pipeline de transcription a été implémenté sous la forme d'une chaîne de traitement clairement structurée, visant à séparer les responsabilités et à faciliter l'orchestration des campagnes run / batch.

Dans un premier temps, les fichiers audios en entr e sont identifi s et pr par s. Cette phase inclut le scan des r pertoires audio, la r cup ration des m tadonn es pertinentes (dur e, format) et, si n cessaire, la conversion ou la normalisation des fichiers afin de garantir leur compatibilit  avec le moteur de transcription. Cette  tape permet  galement de d tecter en amont les fichiers probl matiques et d  viter des erreurs lors de la phase de calcul.

Une fois les donn es pr par es, les fichiers audios sont organis s en lots destin s    tre trait s lors d une campagne de transcription. Ce d coupage en batches permet de contr ler la charge de calcul et de m moire associ e   chaque ex cution, tout en facilitant la reprise des traitements en cas d incident.

7.3 Impl mentation de la transcription multi-processus

Le c ur du syst me repose sur l ex cution parall le de plusieurs processus de transcription. Chaque processus charge une instance du mod le Whisper s lectionn  et traite s quentiellement un sous-ensemble de fichiers audio qui lui est attribu . Cette approche permet de contourner les limitations du multi-threading Python et d exploiter efficacement les ressources CPU disponibles.

L impl mentation multi-processus n cessite une attention particuli re   la gestion des ressources partag es. En particulier, le chargement simultan  de plusieurs mod les Whisper peut entra ner une consommation m moire  lev e. Afin de limiter ce risque, le nombre de processus est param trable et adapt  en fonction de la taille du mod le utilis . Cette flexibilit  permet d ajuster dynamiquement le compromis entre d bit de transcription et stabilit  du syst me.

Chaque processus fonctionne de mani re autonome, ce qui limite l impact d un  ventuel  chec sur l ensemble de la campagne. En cas d erreur lors du traitement d un fichier audio, celle-ci est consign e dans les journaux d ex cution sans interrompre les autres processus.

L  quilibrage de la charge de calcul entre les diff rents processus de transcription constitue un point cl  pour maximiser le d bit global du syst me. Cette probl matique peut  tre formul e comme un probl me de partition visant   r partir les fichiers audio de mani re    quilibrer les dur es totales $\{D_1, \dots, D_k\}$ affect es   chaque processus, ce qui correspond   un probl me NP-hard.

Dans le cadre de ce projet, une strat gie gloutonne (greedy algorithm) a  t  mise en  uvre afin de r partir les fichiers audio entre les processus de fa on approximativement  quilibr e. Bien que cette approche ne garantisse pas une solution optimale au sens th orique, elle s est r v l e efficace en pratique pour limiter les d s quilibres de charge et am liorer l exploitation des ressources CPU.

7.4 Gestion des sorties et des journaux d'ex cution

Les transcriptions produites par le moteur Whisper sont enregistr es sous des formats exploitables par la plateforme Station TV. Les sorties textuelles sont g n r es de mani re syst matique et associ es aux m tadonn es correspondantes, telles que l'identifiant du fichier audio, la dur e du segment et les param tres de transcription utilis s.

En parall le, un syst me de journalisation a  t  mis en place afin de tracer pr cis ment le d roulement des campagnes de transcription. Les journaux contiennent notamment :

- Les temps de traitement par fichier et par processus.
- Les erreurs ou anomalies rencontr es ;
- Les informations de d but et de fin d' cution.

Ces journaux jouent un r le central dans l'analyse a posteriori des performances et dans la reproductibilit  des exp rimentations.

7.5 Supervision et collecte des m triques QoS

La supervision du syst me est impl ment e comme un module ind pendant, ex cut  en parall le du pipeline de transcription. Ce module collecte p riodiquement des informations sur l'utilisation des ressources syst me, telles que la charge CPU, la consommation m moire, la consommation en kWh, une estimation de prix et l'I/O du disque sans perturber le d roulement des traitements.

Les m triques collect es sont stock es sous forme structur e afin de faciliter leur exploitation ult rieure. Cette s paration entre calcul et supervision permet de garantir que les mesures refl tent fid lement le comportement du syst me, sans introduire de biais significatif li    l'instrumentation.

La collecte continue des m triques QoS est particuli rement importante lors des campagnes longues, car elle permet de d tecter d' ventuelles d rives de performance ou des ph nom nes de saturation progressive des ressources.

7.6 Robustesse et gestion des erreurs

Un des objectifs majeurs de l'impl mentation est d'assurer la robustesse du syst me lors d' cutions intensives. Plusieurs m canismes ont  t  int gr s   cette fin. Tout d'abord, les traitements sont d coup s en unit s ind pendantes, ce qui limite la propagation des erreurs. Ensuite, les exceptions lev es lors de la transcription d'un fichier audio sont captur es et enregistr es, sans provoquer l'arr t global du pipeline.

Par ailleurs, des sauvegardes régulières des résultats intermédiaires sont réalisées afin de réduire le risque de perte de données en cas d'incident matériel ou logiciel. Cette approche est cohérente avec l'objectif d'industrialisation du pipeline et facilite la reprise des traitements.

7.7 Bilan de l'implémentation

L'implémentation du système de transcription audio haute performance traduit concrètement les choix techniques formulés au chapitre précédent. Elle aboutit à un pipeline structuré, capable de traiter des volumes importants de données audio de manière parallèle et contrôlée, tout en fournissant des informations détaillées sur son comportement.

Cette réalisation constitue la base sur laquelle reposent les campagnes de tests et d'évaluation présentées dans le chapitre suivant. Les performances mesurées et les analyses associées permettront de valider les objectifs du projet et d'identifier les axes d'amélioration possibles.

8. Campagnes de tests et protocole expérimental

L'évaluation d'un système de transcription audio à grande échelle ne peut se limiter à des observations ponctuelles ou à des impressions qualitatives. Afin de valider objectivement les performances, la robustesse et la qualité du pipeline développé, il est indispensable de définir un protocole expérimental rigoureux, reproductible et cohérent avec les objectifs du projet. Ce chapitre décrit les campagnes de tests menées, les jeux de données utilisés, les paramètres expérimentaux retenus ainsi que la méthodologie de mesure des métriques présentées dans la suite du rapport.

8.1 Objectifs des campagnes de tests

Les campagnes de tests ont été conçues pour répondre à plusieurs objectifs complémentaires. Le premier objectif est de mesurer les performances globales du système de transcription, en particulier le débit de traitement (throughput) et le temps total nécessaire pour transcrire de grandes quantités d'audio. Le second objectif est d'évaluer la stabilité du pipeline lors d'exécutions longues et intensives, en observant l'évolution de l'utilisation des ressources système et l'apparition éventuelle d'erreurs ou de dérives de performance.

Ces objectifs impliquent de tester le système dans des conditions représentatives d'un usage réel au sein de la plateforme Station TV, tout en conservant un cadre expérimental maîtrisé.

8.2 Jeux de données audio

Les tests ont été réalisés à partir de bases audio issues de la plateforme Station TV. Les fichiers audios proviennent de la capture de chaînes de télévision de la TNT et présentent une grande diversité de contenus : journaux télévisés, émissions de débat, programmes culturels,

publicités et séquences musicales. Cette diversité est essentielle pour évaluer la robustesse du système face à des conditions audio hétérogènes.

Les fichiers audios sont majoritairement encodés en format compressé et ont été préalablement normalisés afin de garantir leur compatibilité avec le pipeline de transcription. La durée des fichiers varie de quelques minutes à plusieurs dizaines de minutes, ce qui permet d'analyser le comportement du système aussi bien sur des segments courts que sur des séquences longues.

Pour certaines campagnes, un sous-ensemble représentatif des données a été utilisé afin de faciliter les comparaisons entre différentes configurations. Pour d'autres campagnes, des volumes plus importants ont été mobilisés afin de tester la montée en charge et la stabilité du système sur des durées prolongées.

8.3 Configuration matérielle et logicielle des tests

L'ensemble des campagnes de tests a été réalisé sur la station Dell Precision 5820 mise à niveau dans le cadre du projet. Cette station constitue la plateforme de référence pour l'évaluation des performances.

Sur le plan logiciel, les tests ont été effectués dans un environnement contrôlé, incluant les dépendances nécessaires au fonctionnement du pipeline de transcription et des modules de supervision. Les paramètres du système, tels que le nombre de processus parallèles, la taille des lots de fichiers audio et le modèle Whisper utilisé, sont explicitement définis pour chaque campagne de tests.

Afin de garantir la comparabilité des résultats, les campagnes sont réalisées dans des conditions aussi proches que possible, en évitant toute charge concurrente significative sur la machine lors des expérimentations.

8.4 Protocole de caractérisation des performances ASR

La caractérisation des performances du système de reconnaissance vocale automatique repose sur un protocole expérimental structuré, visant à fournir des mesures robustes et comparables des temps d'exécution et de l'utilisation des ressources système.

La métrique principale retenue est le temps de réponse RT, défini comme le temps nécessaire au traitement complet d'un fichier audio de durée D. À partir de cette mesure, le débit de transcription (throughput Th) est calculé comme le rapport entre la durée audio traitée et le temps réel de traitement. Un throughput $Th > 1$ signifie que le système traite l'audio plus rapidement que le temps réel.

8.4.1 Métriques d'entrées/sorties disque

En complément des métriques CPU et mémoire, le débit des entrées/sorties disque (I/O) est mesuré en continu durant l'exécution des campagnes de transcription. Cette métrique, exprimée en mégaoctets par seconde (MB/s), permet d'évaluer l'impact des accès disque sur les performances globales du pipeline.

La mesure de l'I/O vise à déterminer si le système est limité par les accès disque ou s'il demeure principalement borné par la capacité de calcul CPU. Elle permet également de valider la compatibilité du pipeline avec des infrastructures de stockage standard, sans recours à des dispositifs hautes performances dédiés.

8.4.2 Consommation énergétique

La consommation énergétique du système de transcription est également prise en compte dans le cadre de l'évaluation des performances. Elle est mesurée sous forme de puissance instantanée (en Watts) et d'énergie cumulée sur la durée des campagnes de transcription (en kilowattheures, kWh).

Cette métrique permet de caractériser l'impact énergétique des traitements batch à grande échelle et d'évaluer la viabilité de l'approche CPU-only retenue pour le projet Station TV, notamment dans une perspective d'exploitation continue ou industrielle.

8.4.3 Estimation du coût d'exploitation

Enfin, une estimation du coût d'exploitation est réalisée à partir des caractéristiques matérielles de la station de calcul et des mesures de consommation énergétique. Cette estimation repose sur la détection automatique des composants matériels utilisés (processeur, mémoire vive) et sur la durée effective des campagnes de transcription.

Le coût ainsi estimé ne correspond pas à un coût réel de facturation, mais constitue un indicateur comparatif permettant d'évaluer l'impact économique relatif des différentes configurations testées, en particulier selon la taille du modèle Whisper utilisé.

8.5 Détection des pics mémoire et I/O par NMS

Soit une métrique système α (ex. Memory_GB, Read_MB/s, etc.) observée sous forme d'une série temporelle discrète :

$$\mathcal{S} = \{(t_i, \alpha_i)\}_{i=1}^n, t_i < t_{i+1}$$

où t_i est l'instant d'échantillonnage et $\alpha_i = \alpha(t_i)$ la valeur mesurée.

8.5.1 Estimation d'une période caractéristique des pics

On définit d'abord un seuil robuste basé sur le 75^e percentile (P75) :

$$q_{0.75} = P75(\{\alpha_i\}_{i=1}^n)$$

On consid re ensuite l'ensemble des indices "au-dessus P75" :

$$\mathcal{I} = \{i \in \{1, \dots, n\} \mid \alpha_i > q_{0.75}\}$$

En notant $\mathcal{I} = \{i_1 < i_2 < \dots < i_m\}$, on calcule les inter-distances :

$$\Delta_j = t_{i_{j+1}} - t_{i_j}, j = 1, \dots, m - 1$$

La p riode caract ristique des pics est estim e par la m diane :

$$T = \text{median}(\{\Delta_j\}_{j=1}^{m-1})$$

8.5.2 D finition de la fen tre temporelle

On choisit une fen tre W satisfaisant la contrainte :

$$W < \frac{T}{2}$$

Dans nos campagnes, on utilise :

$$W = 0.4 T$$

8.5.3 Non-Maxima Suppression (NMS)

L'objectif est de ne conserver que des maxima locaux dominants. On dit qu'un point (t_i, α_i) est supprim  s'il existe un point (t_j, α_j) tel que :

$$|t_i - t_j| < \frac{W}{2} \text{ et } \alpha_j > \alpha_i$$

L'ensemble des indices conserv s apr s NMS est donc :

$$\mathcal{K} = \left\{ i \mid \nexists j \neq i, |t_i - t_j| < \frac{W}{2} \wedge \alpha_j > \alpha_i \right\}$$

et la s rie filtr e :

$$\mathcal{S}_{\text{NMS}} = \{(t_i, \alpha_i)\}_{i \in \mathcal{K}}$$

8.5.4 Statistiques robustes sur la s rie filtr e

Sur les valeurs $\{\alpha_i\}_{i \in \mathcal{K}}$, on calcule :

$$m = \text{median}(\{\alpha_i\}_{i \in \mathcal{K}}), M = \max(\{\alpha_i\}_{i \in \mathcal{K}})$$

On d finit ensuite un seuil adaptatif :

$$b = \frac{|M - m|}{2}$$

8.5.5 Détection des pics significatifs

Les pics significatifs sont les points qui vérifient :

$$\alpha_i > m + b$$

On note l'ensemble des indices de pics :

$$\mathcal{P} = \{i \in \mathcal{K} \mid \alpha_i > m + b\}$$

8.5.6 Statistiques finales sur les pics

Enfin, on retient comme indicateurs :

- **médiane des pics :**

$$\text{median}(\{\alpha_i\}_{i \in \mathcal{P}})$$

- **maximum des pics :**

$$\max(\{\alpha_i\}_{i \in \mathcal{P}})$$

Ces indicateurs permettent de caractériser simultanément le comportement “typique” des maxima (via la médiane) et la valeur extrême atteinte (via le maximum), tout en limitant l'influence des fluctuations de bruit grâce au filtrage NMS.

8.6 Paramètres expérimentaux

Chaque campagne de transcription est caractérisée par un ensemble de paramètres expérimentaux, parmi lesquels figurent :

- La taille du modèle Whisper utilisé (tiny, base, small, medium ou large).
- Le nombre de processus de transcription lancés en parallèle.
- La taille des batches audio traités par chaque processus.
- La durée totale des fichiers audio soumis au pipeline.

Ces paramètres sont choisis de manière à explorer différents compromis entre performance et qualité, tout en respectant les contraintes matérielles identifiées. Le nombre de processus est notamment ajusté en fonction de la taille du modèle afin d'éviter une saturation de la mémoire vive.

Pour certaines configurations, plusieurs exécutions successives sont réalisées afin d'évaluer la reproductibilité des résultats et de limiter l'impact de variations ponctuelles liées au système.

Afin de limiter l'impact de la variabilité d'exécution liée au système d'exploitation, à la gestion mémoire et à la contention des ressources CPU, chaque configuration expérimentale a été exécutée plusieurs fois.

Pour les modèles Whisper de petite et moyenne taille (tiny, base et small), un nombre de répétitions $N = 10$ s'est révélé suffisant pour obtenir une estimation stable du temps de réponse RT.

En revanche, pour les modèles de plus grande taille (medium et large), les temps d'exécution plus longs et la pression mémoire accrue induisent une variabilité plus importante. Dans ce cas, une augmentation du nombre de répétitions expérimentales ($N = 20$ à 30) permet d'affiner l'estimation statistique du temps de réponse et de réduire l'influence de fluctuations ponctuelles.

Pour l'ensemble des expériences, la valeur retenue pour l'analyse correspond à la médiane des temps de réponse observés.

8.7 Méthodologie de mesure des performances

Les performances du système sont évaluées à l'aide des métriques définies au chapitre 3. Le temps réel total de traitement est mesuré pour chaque campagne, depuis le lancement du pipeline jusqu'à la fin de la transcription du dernier fichier audio. À partir de cette mesure et de la durée audio totale traitée, le throughput est calculé selon la relation définie précédemment.

L'utilisation des ressources CPU et mémoire est mesurée en continu durant l'exécution des campagnes de tests. Ces mesures permettent d'identifier les phases de charge maximale, les éventuels phénomènes de saturation et les variations de comportement au cours du temps. Les données collectées sont ensuite agrégées et analysées afin de produire des indicateurs synthétiques, tels que les valeurs moyennes et maximales observées.

Le taux de réussite des transcriptions est évalué en comparant le nombre de fichiers audio effectivement transcrits au nombre total de fichiers soumis au pipeline. Toute erreur ou interruption est consignée dans les journaux d'exécution et prise en compte dans l'analyse.

8.8 Chargement et mise en cache des modèles

Les campagnes de tests ont été réalisées en maintenant les modèles Whisper chargés en mémoire entre les différentes transcriptions, afin d'éviter des rechargements répétés des poids du modèle. Cette stratégie de mise en cache permet de réduire les temps d'initialisation et de se rapprocher d'un scénario d'exploitation réel, dans lequel le système fonctionne de manière continue.

Ce choix a toutefois un impact direct sur la consommation mémoire observée, dans la mesure où les poids des modèles restent résidents en mémoire pendant toute la durée des campagnes de transcription. Les mesures de consommation mémoire présentées dans ce rapport correspondent donc à ce scénario avec modèles mis en cache.

8.9 Limites du protocole expérimental

Bien que le protocole expérimental ait été conçu pour être rigoureux et représentatif, certaines limites doivent être soulignées. Les résultats obtenus sont spécifiques à la configuration matérielle et logicielle utilisée et peuvent varier sur d'autres plateformes.

Néanmoins, le protocole adopté permet de comparer de manière cohérente les différentes configurations testées et de dégager des tendances fiables quant aux performances et à la qualité du système de transcription.

8.10 Synthèse du protocole

Les campagnes de tests décrites dans ce chapitre constituent le cadre expérimental sur lequel reposent les résultats présentés dans le chapitre suivant. En définissant précisément les données utilisées, les paramètres expérimentaux et les méthodes de mesure, ce protocole garantit la transparence et la reproductibilité des évaluations menées dans le cadre du projet.

9. Résultats expérimentaux et analyse des performances

Ce chapitre présente les résultats obtenus lors des campagnes de transcription audio à grande échelle décrites au chapitre précédent. L'analyse s'appuie sur les métriques de performance et de qualité définies au chapitre 3, et vise à évaluer de manière objective la capacité du système à répondre aux objectifs fixés. Les résultats sont analysés à la fois sous l'angle des performances temporelles, de l'utilisation des ressources et de la qualité linguistique des transcriptions produites.

9.1 Résultats globaux des campagnes de transcription

Les campagnes de tests ont permis de transcrire plusieurs centaines d'heures de données audio issues de la TNT, en utilisant différents modèles Whisper (*tiny*, *base*, *small*, *medium* et *large*) et des configurations de parallélisation adaptées à chacun.

Dans un premier temps, une campagne de référence a été menée sur le jeu de données **BaseMod**, composé de cinq fichiers audio de durées croissantes (240, 480, 720, 960 et 1200 secondes). Cette campagne vise à caractériser le comportement des différents modèles Whisper en fonction de la durée des fichiers audio et à établir une comparaison initiale des débits de transcription.

Pour chaque campagne, la durée audio totale T_{audio} et le temps réel total $T_{\text{réel}}$ ont été mesurés, permettant de calculer le débit de transcription global selon la relation :

$$Th = \frac{T_{\text{audio}}}{T_{\text{réel}}}$$

Les résultats obtenus sur **BaseMod** montrent que le système est capable d'atteindre des débits de transcription élevés, compatibles avec un traitement à grande échelle. Les modèles *tiny* et *base* permettent un traitement largement plus rapide que le temps réel, tandis que les modèles *medium* et *large* offrent un compromis plus favorable en termes de qualité linguistique, au prix d'un temps de traitement accru.

De manière générale, les objectifs de performance définis au chapitre 3 sont atteints pour les modèles *tiny*, *base*, *small* et *medium*. Le modèle *large* se situe à la limite des capacités de la plateforme, tout en restant exploitable grâce à la montée en charge mémoire réalisée.

Le tableau suivant présente les valeurs de throughput observées pour les différents modèles Whisper lors de cette campagne de référence **BaseMod**.

Modèle Whisper	Throughput (Th)
Tiny	6.23
Base	3.51
Small	1.17
Medium	0.47
Large	0.25

Ces résultats mettent en évidence une décroissance significative du throughput avec l'augmentation de la taille du modèle.

Dans un second temps, des campagnes de transcription longue durée ont été réalisées sur le jeu de données BaseBatch, constitué de 32 dossiers contenant chacun jusqu'à 24 fichiers audio d'une durée d'environ 1 heure. Ces campagnes visent à évaluer le comportement du système dans des conditions proches d'un usage réel, en mettant l'accent sur la stabilité, la consommation des ressources et la capacité à soutenir un traitement massif et continu.

Les résultats de ces campagnes longues sont analysés dans les sections suivantes et synthétisés en fin de chapitre afin de comparer les modèles Whisper du point de vue des performances, de la consommation mémoire et de l'exploitabilité à long terme.

9.2 Analyse du débit de transcription (Throughput)

Le débit de transcription constitue la métrique principale pour évaluer la capacité du système à traiter des volumes importants de données audio. Les résultats observés confirment une relation inverse entre la taille du modèle Whisper et le throughput obtenu.

Dans cette section, l'analyse du throughput s'appuie principalement sur la campagne de référence **BaseMod** afin de comparer les modèles dans des conditions contrôlées. Les campagnes **BaseBatch** sont mobilisées dans les sections dédiées à la stabilité et à l'exploitabilité long terme (ressources, pics NMS et synthèse comparative).

Pour le modèle *small*, le système atteint un débit largement supérieur au temps réel, ce qui permet de traiter plusieurs heures d'audio en une heure réelle. Cette configuration est particulièrement adaptée aux campagnes nécessitant un traitement rapide, par exemple pour des analyses exploratoires ou des traitements préliminaires.

Le modèle *medium* présente un débit plus modéré, mais reste compatible avec un traitement à grande échelle. Dans cette configuration, le système atteint un throughput compatible avec un traitement quasi temps réel selon la configuration retenue, ce qui signifie que la transcription peut être réalisée en temps quasi réel ou légèrement accéléré. Toutefois, l'analyse détaillée des ressources et des pics mémoire (cf. sections 9.9–9.11) montre que ce

modèle réduit significativement la marge de sécurité mémoire lors d'exécutions prolongées, ce qui justifie une supervision plus attentive dans un contexte de production continue.

Enfin, le modèle *large* se distingue par un débit plus faible, parfois inférieur à 1. Cela implique que le traitement de longues campagnes nécessite plusieurs heures, voire plusieurs jours, selon le volume de données. Toutefois, ce modèle offre une qualité linguistique nettement supérieure, ce qui peut justifier son utilisation pour des campagnes ciblées ou des données à forte valeur ajoutée.

Ces résultats illustrent clairement le compromis inhérent entre performance et qualité, et soulignent l'importance d'adapter le choix du modèle aux objectifs de chaque campagne.

9.3 Temps moyen de traitement par fichier

Le temps moyen de traitement par fichier, défini comme :

$$T_{\text{moy}} = \frac{T_{\text{réel}}}{N}$$

permet d'évaluer la régularité du pipeline de transcription. Les mesures montrent que, pour une configuration donnée, les temps de traitement par fichier restent relativement homogènes, malgré la diversité des durées et des contenus audio.

Des variations sont néanmoins observées pour les fichiers les plus longs ou présentant des conditions audio complexes. Ces variations restent toutefois limitées et ne remettent pas en cause la stabilité globale du système. Elles s'expliquent principalement par la durée intrinsèque des fichiers audio et par la complexité du signal sonore, qui influence le temps de calcul du modèle de transcription.

9.4 Utilisation des ressources CPU

L'analyse de l'utilisation CPU met en évidence une exploitation efficace des ressources de calcul disponibles. Lors des campagnes multi-processus, la charge CPU atteint des valeurs élevées, traduisant une bonne parallélisation des traitements et une limitation des phases d'inactivité. Pour les modèles *small* et *medium*, l'utilisation CPU moyenne se situe à un niveau proche de la saturation, sans toutefois provoquer de dégradation notable des performances. Cela indique que le nombre de processus lancé est adapté à la capacité du processeur et permet de maximiser le débit de transcription.

Dans le cas du modèle *large*, l'utilisation CPU reste élevée, mais certaines phases de traitement montrent une diminution de la charge. Ces variations s'expliquent par des contraintes mémoire plus importantes, qui peuvent limiter temporairement le parallélisme effectif.

La consommation énergétique est analysée dans la section 9.8, sur la base des mesures réalisées lors des campagnes longues.

9.5 Consommation mémoire et stabilité du système

La consommation mémoire constitue un point critique de l'analyse, en particulier pour les modèles Whisper de grande taille. Les résultats montrent que la mise à niveau vers 256 Go de RAM ECC permet de maintenir la consommation mémoire globale en deçà des limites critiques, même lors de campagnes intensives.

Pour les modèles *small* et *medium*, la mémoire utilisée reste largement inférieure à la capacité disponible, offrant une marge de sécurité confortable. Cette situation contribue à la stabilité du système et limite les risques d'erreurs liées à la saturation mémoire.

Le modèle *large* présente une consommation mémoire nettement plus élevée, en raison du chargement simultané de plusieurs instances du modèle. Néanmoins, grâce à une limitation appropriée du nombre de processus, le système reste stable et ne présente pas de recours significatif au swapping disque. Ce résultat valide l'intérêt de la montée en charge matérielle réalisée au début du projet.

9.6 Taux de réussite des transcriptions

Le taux de réussite des transcriptions, défini par :

$$R = \frac{N_{\text{succès}}}{N_{\text{total}}}$$

est resté très élevé sur l'ensemble des campagnes réalisées. La grande majorité des fichiers audio soumis au pipeline ont été transcrits avec succès, sans interruption majeure ni perte de données.

Les rares échecs observés sont principalement liés à des fichiers audio corrompus ou à des anomalies en entrée, et non à des défaillances du système de transcription lui-même. Ces erreurs ont été correctement détectées et consignées dans les journaux d'exécution, sans interrompre le déroulement global des campagnes.

9.7 Utilisation des entrées/sorties disque

L'analyse des débits d'entrées/sorties disque montre que le pipeline de transcription génère une charge I/O relativement faible par rapport aux capacités de stockage disponibles sur la station de calcul. Les accès disque sont principalement liés à la lecture des fichiers audio en entrée et à l'écriture des résultats de transcription.

Les valeurs observées restent largement inférieures aux limites matérielles des dispositifs de stockage utilisés, ce qui indique que le système n'est pas contraint par les performances I/O. Cette observation confirme que le traitement de transcription est principalement borné par la capacité de calcul CPU et non par les accès disque, ce qui renforce la scalabilité de la solution sur des infrastructures standard.

9.8 Consommation énergétique du système

Les mesures de consommation énergétique effectuées lors des campagnes de transcription mettent en évidence une consommation stable sur la durée des traitements batch. La puissance instantanée observée reflète l'exploitation soutenue des ressources CPU, tandis que l'énergie cumulée permet d'estimer l'impact global des campagnes longues.

À l'échelle hebdomadaire, la consommation énergétique mesurée reste modérée au regard des volumes de données audio traités. Ce résultat confirme que l'approche CPU-only retenue permet d'assurer un traitement à grande échelle tout en maintenant une consommation énergétique compatible avec un usage prolongé.

9.9 Analyse des pics mémoire

L'analyse des pics mémoire met en évidence une augmentation progressive et maîtrisée de la consommation en fonction de la taille du modèle Whisper utilisé.

Pour les modèles *tiny* et *base*, la médiane des pics mémoire reste inférieure respectivement à 23 GB et 32 GB, avec des maxima très proches de ces valeurs, traduisant un comportement stable et prévisible.

Le modèle *small* présente une consommation plus élevée, avec une médiane des pics autour de 125 GB, mais sans dépassement brutal, ce qui demeure compatible avec la capacité mémoire disponible sur la station de calcul.

En revanche, le modèle *medium* atteint une médiane des pics mémoire de l'ordre de 183 GB, avec des maxima proches de 185 GB. Bien que cette valeur reste inférieure au seuil critique de 256 GB, elle réduit significativement la marge de sécurité et rend le système plus sensible aux variations de charge lors d'exécutions prolongées.

9.10 Analyse des pics I/O

Les analyses des entrées/sorties disque montrent que, quel que soit le modèle Whisper considéré, la charge I/O reste globalement modérée et ponctuelle. Les médianes globales des débits sont très faibles, indiquant que le système n'est pas limité par les performances disque. Les pics I/O identifiés par la méthode NMS correspondent principalement aux phases de lecture des fichiers audio et d'écriture des transcriptions. Les débits maximaux observés en lecture restent inférieurs à 235 MB/s, et ceux en écriture inférieurs à 75 MB/s, valeurs largement supportées par une infrastructure de stockage standard.

Ces résultats confirment que le pipeline de transcription est essentiellement borné par le calcul CPU et la mémoire, et non par les entrées/sorties disque, ce qui renforce la scalabilité de l'approche retenue.

Modèle : TINY

Mémoire

Métrique	N bruts	T est.	W	N après NMS	Médiane m	Max	Seuil b	Nb pics	Médiane pics	Max pics	Max global	Médiane globale
Memory_%	4728	50s	30s	4652	8.800	8.900	0.050	12	8.900	8.900	8.900	8.800
Memory_GB	4728	50s	30s	2662	22.530	22.660	0.065	23	22.610	22.660	22.660	22.530

I/O

Métrique	N bruts	T est.	W	N après NMS	Médiane m	Max	Seuil b	Nb pics	Médiane pics	Max pics	Max global	Médiane globale
IO_%	4730	70s	30s	1720	0.050	40.480	20.215	11	32.830	40.480	40.480	0.040
Read_MB/s	4730	60s	30s	1725	0.040	201.750	100.855	11	142.900	201.750	201.750	0.030
Write_MB/s	4730	60s	30s	1626	0.200	26.130	12.965	19	16.940	26.130	26.130	0.160

Modèle : BASE

Mémoire

Métrique	N bruts	T est.	W	N après NMS	Médiane m	Max	Seuil b	Nb pics	Médiane pics	Max pics	Max global	Médiane globale
Memory_%	6276	50s	30s	2116	11.440	12.690	0.625	36	12.155	12.690	12.690	11.140
Memory_GB	6276	50s	30s	2086	29.630	32.560	1.465	98	31.420	32.560	32.560	28.780

I/O

Métrique	N bruts	T est.	W	N après NMS	Médiane m	Max	Seuil b	Nb pics	Médiane pics	Max pics	Max global	Médiane globale
IO_%	6276	70s	30s	2298	0.050	40.720	20.335	14	35.240	40.720	40.720	0.040
Read_MB/s	6276	60s	30s	2374	0.040	221.440	110.700	21	142.720	221.440	221.440	0.030
Write_MB/s	6276	60s	30s	2154	0.210	26.460	13.125	23	17.540	26.460	26.460	0.160

Modèle : SMALL

Mémoire

Métrique	N bruts	T est.	W	N après NMS	Médiane m	Max	Seuil b	Nb pics	Médiane pics	Max pics	Max global	Médiane globale
Memory_%	8470	50s	30s	5380	48.400	49.100	0.350	21	48.800	49.100	49.100	48.400
Memory_GB	8470	50s	30s	2581	123.810	125.570	0.880	15	124.840	125.570	125.570	123.690

I/O

Métrique	N bruts	T est.	W	N après NMS	Médiane m	Max	Seuil b	Nb pics	Médiane pics	Max pics	Max global	Médiane globale
IO_%	8478	50s	30s	3496	0.040	46.030	22.995	24	30.905	46.030	46.030	0.040
Read_MB/s	8478	60s	30s	3581	0.030	229.900	114.935	23	144.400	229.900	229.900	0.020
Write_MB/s	8478	60s	30s	2880	0.200	59.140	29.470	3	49.430	59.140	59.140	0.160

Modèle : MEDIUM

Mémoire

Métrique	N bruts	T est.	W	N après NMS	Médiane m	Max	Seuil b	Nb pics	Médiane pics	Max pics	Max global	Médiane globale
Memory_%	12451	50s	30s	6702	70.000	72.300	1.150	2457	71.600	72.300	72.300	69.900
Memory_GB	12451	60s	30s	3210	179.040	184.760	2.860	1222	182.745	184.760	184.760	178.690

I/O

Métrique	N bruts	T est.	W	N après NMS	Médiane m	Max	Seuil b	Nb pics	Médiane pics	Max pics	Max global	Médiane globale
IO_%	12458	50s	30s	5196	0.040	46.470	23.215	26	32.255	46.470	46.470	0.040
Read_MB/s	12458	60s	30s	5311	0.030	231.990	115.980	27	149.320	231.990	231.990	0.020
Write_MB/s	12458	60s	30s	4278	0.200	73.530	36.665	1	73.530	73.530	73.530	0.160

9.11 Synthèse comparative des modèles Whisper

Le tableau suivant propose une synthèse comparative des principaux indicateurs de performance et de consommation de ressources pour les différents modèles Whisper évalués, sur la base des campagnes de transcription longue durée **BaseBatch** et des analyses présentées précédemment.

Cette synthèse met en évidence les compromis entre performance, consommation de ressources et exploitabilité long terme, et sert de base à la prise de recul proposée au chapitre suivant.

Tableau récapitulatif — Modèles Whisper

Métrique	tiny	base	small	medium
Thread number k	—	—	30	—
CPU rate %	—	—	85 %	—
Duration / Thread (h)	24	24	8	5
Total duration (h)	720	720	240	150
Th init	39,8	30,1	6,5	4,5
Th opt	55,32	41,77	10,19	4,33
RT (h)	13,16	17,43	23,56	34,64
Memory GB	22,61	31,42	124,84	182,75
Memory %	8,90 %	12,16 %	48,80 %	71,60 %

La synthèse comparative présentée dans cette section doit toutefois être interprétée à la lumière de certaines limites expérimentales concernant le modèle Whisper *large*. En raison de contraintes temporelles liées au déroulement du projet, il n'a pas été possible de mener

des campagnes de tests longues et répétées pour ce modèle dans des conditions strictement équivalentes à celles des autres tailles évaluées.

Par ailleurs, la stratégie retenue consistant à maintenir les modèles Whisper chargés en mémoire afin de se rapprocher d'un scénario d'exploitation réel implique une consommation mémoire très élevée pour le modèle *large*. Dans ce contexte, la poursuite de campagnes intensives avec plusieurs processus parallèles aurait exposé le système à un risque significatif de saturation mémoire, susceptible d'entraîner une instabilité du pipeline de transcription, voire un crash du système.

En conséquence, les résultats associés au modèle *large* doivent être considérés comme indicatifs et principalement destinés à positionner ce modèle dans l'espace des compromis entre qualité linguistique, performances et consommation de ressources, plutôt que comme une évaluation exhaustive de son exploitabilité à grande échelle.

9.12 Discussion et interprétation des résultats

L'ensemble des résultats obtenus met en évidence la capacité du système développé à répondre aux objectifs fixés au début du projet. La montée en charge matérielle permet d'exploiter des modèles de transcription plus performants, tandis que la structuration du pipeline et la parallélisation multi-processus assurent des débits compatibles avec un traitement massif des données audio.

Les résultats confirment également l'importance de disposer de métriques de QoS pour analyser finement les compromis entre performance, qualité et consommation de ressources. Ces métriques constituent un outil précieux pour guider les choix de configuration et adapter le système aux besoins spécifiques de chaque campagne de transcription.

10. Prise de recul, limites et perspectives

Ce dernier chapitre propose une analyse critique du travail réalisé dans le cadre du projet de transcription audio haute performance sur Station TV. Au-delà des résultats expérimentaux présentés précédemment, il s'agit ici d'évaluer le projet avec un recul d'ingénierie, en mettant en évidence les apports concrets, les limites identifiées et les perspectives d'évolution possibles du système au sein de l'écosystème Station TV.

10.1 Stabilité long terme et robustesse du système

Les campagnes de transcription longue durée, combinées à l'analyse des séries temporelles par filtrage NMS, mettent en évidence un comportement globalement stable du pipeline de transcription sur l'ensemble des modèles évalués.

Pour les modèles *tiny* et *base*, les pics mémoire et I/O restent faibles et peu fréquents, avec des maxima très proches des valeurs médianes, traduisant une exécution régulière et prévisible. Ces modèles présentent une large marge de sécurité vis-à-vis des ressources matérielles disponibles, ce qui les rend particulièrement adaptés à un usage continu et non supervisé.

Le modèle *small* constitue un compromis intermédiaire : bien que sa consommation mémoire soit significativement plus élevée, l'analyse NMS montre que les pics restent contenus et compatibles avec la capacité de la station de calcul, sans phénomène de dérive progressive sur la durée.

À l'inverse, le modèle *medium* atteint des niveaux de consommation mémoire proches des limites de confort du système. Si aucun dépassement critique n'a été observé, la réduction de la marge mémoire disponible implique une sensibilité accrue aux variations de charge et justifie la mise en place d'une supervision plus attentive lors d'exécutions prolongées.

10.2 Apports du projet

Le projet a permis de consolider et d'industrialiser une chaîne de transcription audio automatique capable de traiter des volumes importants de données issues de la TNT. L'un des apports majeurs réside dans la montée en charge matérielle de la station de calcul, qui constitue un prérequis indispensable à l'exploitation de modèles de reconnaissance vocale de grande taille. Le passage à une configuration disposant de 256 Go de mémoire vive ECC a permis de lever une contrainte structurelle forte et d'envisager des campagnes de transcription plus ambitieuses, tant en termes de volume que de qualité.

Sur le plan logiciel, le projet a abouti à un pipeline de transcription structuré, intégrant des mécanismes de parallélisation, de supervision et de gestion des erreurs adaptés à un contexte de calcul intensif. La mise en place de métriques de Qualité de Service constitue également un apport significatif. Elle permet de caractériser objectivement les performances du système, de comparer différentes configurations et de fournir des éléments tangibles pour la prise de décision lors du choix des paramètres de transcription.

Enfin, le projet contribue à la pérennisation des travaux de transcription au sein de Station TV, en proposant une solution documentée, reproductible et intégrable par d'autres acteurs du laboratoire. Cette dimension d'industrialisation distingue le travail réalisé d'une simple expérimentation ponctuelle.

L'intégration de métriques énergétiques et d'une estimation du coût d'exploitation constitue un apport important du projet. Au-delà des performances brutes de transcription, ces indicateurs permettent d'évaluer la pertinence du système dans une perspective d'exploitation réelle.

L'estimation du coût, fondée sur la durée d'exécution et les caractéristiques matérielles de la station de calcul, permet de comparer objectivement les différentes configurations de transcription. Elle met en évidence le compromis entre temps de traitement et coût d'exploitation, en particulier lors de l'utilisation de modèles de grande taille.

Cette approche offre un outil d'aide à la décision pour le choix des paramètres de transcription, en fonction des contraintes de performance, de qualité et de coût, et renforce la dimension d'industrialisation du pipeline développé.

10.3 Limites identifiées

Malgré les résultats encourageants obtenus, plusieurs limites doivent être soulignées. La première concerne la dépendance à une architecture CPU-only. Bien que ce choix ait permis de garantir la reproductibilité et la stabilité des exécutions, il limite intrinsèquement les performances maximales atteignables, en particulier pour les modèles Whisper de grande taille. Le throughput obtenu avec le modèle *large* reste inférieur à celui des configurations exploitant une accélération GPU, ce qui peut constituer un frein pour des campagnes de très grande ampleur.

Une seconde limite concerne l'évaluation de la qualité linguistique. Le calcul du Word Error Rate repose sur un échantillonnage de segments audio et ne couvre pas l'intégralité des données transcrites. Bien que cette approche soit couramment utilisée et adaptée aux contraintes du projet, elle ne permet pas de garantir une mesure exhaustive de la qualité sur l'ensemble des contenus traités.

Par ailleurs, le pipeline de transcription reste principalement orienté vers un traitement batch. Si cette approche est adaptée aux campagnes massives, elle limite l'exploitation du système pour des usages nécessitant une transcription en temps quasi réel ou avec des contraintes de latence strictes.

L'ensemble des campagnes de tests présentées dans ce rapport a été réalisé avec une mise en cache des modèles Whisper en mémoire. Ce choix, pertinent dans une perspective d'exploitation continue, influence toutefois les mesures de consommation mémoire, en particulier pour les modèles de taille moyenne et élevée.

Des expérimentations complémentaires réalisées sur une machine personnelle indiquent que la mise en cache des modèles peut entraîner une augmentation notable de la consommation mémoire, tout en permettant une accélération du débit de transcription pour les modèles de petite et moyenne taille (*tiny* à *small*), grâce à la suppression des phases répétées de chargement des poids.

Afin de mieux isoler l'impact du cache des modèles sur la consommation mémoire, une perspective naturelle de ce travail consisterait à reproduire les campagnes de tests sans mise en cache, puis à comparer les profils mémoire obtenus avec ceux présentés dans ce rapport. Cette analyse permettrait de vérifier la correspondance avec les résultats d'analyses antérieures réalisées sans cache et de quantifier précisément le compromis entre performance et consommation mémoire induit par cette stratégie.

Une limite importante du projet concerne l'évaluation expérimentale du modèle Whisper *large*. Bien que ce modèle présente un intérêt majeur en termes de qualité linguistique, les contraintes temporelles du projet n'ont pas permis de conduire des campagnes de tests longues et répétées dans des conditions pleinement stabilisées.

De plus, l'architecture retenue, combinant une exécution CPU-only et une mise en cache persistante des modèles en mémoire, implique une consommation mémoire très élevée pour le modèle *large*. Dans ce contexte, la poursuite de campagnes intensives avec plusieurs processus parallèles aurait significativement accru le risque de saturation mémoire et d'instabilité système, pouvant aller jusqu'au crash du pipeline.

Pour ces raisons, le modèle *large* doit être considéré comme adapté à des campagnes ciblées et ponctuelles, plutôt qu'à un usage massif continu dans l'état actuel de l'architecture.

Enfin, la complexité des données audio issues de la TNT implique que certaines erreurs de transcription restent difficiles à corriger, notamment dans les cas de chevauchement de locuteurs, de bruit intense ou de présence de musique de fond. Ces limites sont en grande partie inhérentes à l'état actuel des technologies de reconnaissance vocale.

10.4 Perspectives d'évolution technique

Plusieurs axes d'évolution peuvent être envisagés à la suite de ce projet. Un premier axe concerne l'intégration d'accélérateurs matériels, tels que des GPU ou des solutions hybrides CPU/GPU. Une telle évolution permettrait d'augmenter significativement le débit de transcription, en particulier pour les modèles de grande taille, et d'élargir les usages possibles du système.

Un second axe porte sur l'optimisation dynamique du pipeline. Il serait envisageable de mettre en place des mécanismes d'auto-ajustement des paramètres d'exécution, tels que le nombre de processus ou la taille des batches, en fonction de l'état du système et des ressources disponibles. Cette approche permettrait d'améliorer la stabilité et d'exploiter plus finement les capacités matérielles.

L'enrichissement des métriques de Qualité de Service constitue également une perspective intéressante. Au-delà des métriques déjà mises en place, des indicateurs plus fins pourraient être introduits, tels que la latence par segment, la distribution des scores de confiance des transcriptions ou l'analyse temporelle des dérives de performance lors des exécutions longues.

10.5 Perspectives d'intégration dans Station TV

Du point de vue de la plateforme Station TV, le système de transcription développé dans ce projet peut servir de base à des évolutions fonctionnelles plus larges. Les transcriptions produites peuvent être intégrées plus étroitement aux modules d'analyse sémantique, de recherche d'information ou de fact-checking, afin de renforcer la valeur ajoutée des services proposés.

À plus long terme, la transcription audio pourrait également être combinée à des approches multimodales, intégrant l'analyse visuelle et textuelle des flux télévisuels. Cette convergence ouvrirait la voie à des services plus avancés, tels que la détection automatique d'événements médiatiques, l'analyse de discours ou la génération de résumés multimodaux.

10.6 Bilan personnel et conclusion générale

Sur le plan personnel et académique, ce projet a permis de développer des compétences transversales en ingénierie des systèmes, en calcul intensif et en évaluation expérimentale. La

confrontation à des problématiques concrètes de montée en charge, de stabilité et de mesure des performances a constitué un apprentissage essentiel, complémentaire aux enseignements théoriques.

En conclusion, le projet de transcription audio haute performance sur Station TV a permis de franchir une étape importante vers une exploitation industrielle de la reconnaissance vocale à grande échelle au sein du LIFAT. Les résultats obtenus démontrent la pertinence des choix effectués et ouvrent des perspectives prometteuses pour l'évolution future de la plateforme Station TV.